Лабороторная работа №1: Гистограммы и плотности распределений

Выполнил: Филь Фёдор
Группа: 5030102/30202

1 Постановка задачи

Даны следующие распределения:

- Нормальное $N(x; 0, 1)$
- Коши $C(x; 0, 1)$
- Лапласа $L\left(x; 0, \frac{1}{\sqrt{2}}\right)$
- Пуассона $P(k; 10)$
- Равномерное $U(x; -\sqrt{3}, \sqrt{3})$

Требуется сгенерировать выборки объёмом $n = 10, 100, 1000$ для каждого из пяти распределений, построить гистограммы выборки и теоретические кривые плотности распределения.

2 Теоретическая часть

Пусть X — случайная величина с функцией распределения $F(x) = P(X \leq x)$. Если $F(x)$ абсолютно непрерывна, то существует плотность вероятности $f(x) = F'(x)$, обладающая свойствами:

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x)\,dx = 1, \quad P(a \leq X \leq b) = \int_a^b f(x)\,dx.$$

Для дискретной случайной величины вероятность задаётся функцией $p(k) = P(X = k)$ с условием $\sum_k p(k) = 1$.
В работе рассматриваются следующие распределения:

- Нормальное $N(x; 0, 1)$: $f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$.
- Коши $C(x; 0, 1)$: $f(x) = \frac{1}{\pi(1+x^2)}$.
- Лапласа $f(x) = \frac{\sqrt{2}}{2} e^{-\sqrt{2}|x|}$.
- Пуассона $P(k; 10)$: $p(k) = \frac{10^k}{k!} e^{-10}$, $k = 0, 1, 2, \ldots$
- Равномерное $U(x; -\sqrt{3}, \sqrt{3})$: $f(x) = \frac{1}{2\sqrt{3}}$ при $|x| < \sqrt{3}$, иначе 0.

Для оценки неизвестной плотности по выборке $\{x_1, \ldots, x_n\}$ используется гистограмма. Область значений разбивается на интервалы (бины) длиной h, и для каждого интервала вычисляется относительная частота:

$$\hat{f}(x) = \frac{\text{число элементов выборки, попавших в интервал, содержащий } x}{n \cdot h}.$$

При $n \to \infty$ и $h \to 0$ гистограмма сходится к теоретической плотности $f(x)$. Цель работы — визуально сравнить гистограммы выборок разного объёма ($n = 10, 100, 1000$) с теоретическими кривыми плотности (или вероятности для Пуассона) и убедиться в сходимости.

3 Реализация

Программная реализация лабораторной работы выполнена на языке Python в среде разработки PyCharm. Для генерации случайных выборок, вычисления теоретических плотностей и построения графиков использовались следующие библиотеки:

- `numpy` — для генерации псевдослучайных чисел из заданных распределений (нормального, Коши, Лапласа, Пуассона, равномерного);
- `scipy.stats` — для вычисления значений теоретической плотности вероятности (`pdf`) для непрерывных распределений и функции вероятности (`pmf`) для распределения Пуассона;
- `matplotlib.pyplot` — для визуализации гистограмм выборок и наложения теоретических кривых.

Суть реализованных методов:

1. Для каждого из пяти распределений (нормальное, Коши, Лапласа, Пуассона, равномерное) заданы параметры в соответствии с условием задачи.
2. Сгенерированы выборки объёмом $n = 10, 100, 1000$ с помощью функций `rvs` (random variates), которые для непрерывных распределений вызывают соответствующие генераторы `numpy.random`, а для Пуассона — `np.random.poisson(10, size)`.
3. Построены нормированные гистограммы (`density=True`) — они являются эмпирической оценкой плотности распределения (или вероятности для дискретного случая). Для непрерывных распределений число интервалов выбиралось автоматически (`bins='auto'`), для Пуассона интервалы зафиксированы шириной 1.
4. Поверх гистограмм наложены теоретические кривые: для непрерывных распределений — функция плотности `pdf`, для Пуассона — точечный график функции вероятности `pmf`.

Связь с теоретической частью: Согласно теории, при увеличении объёма выборки гистограмма (нормированная) должна сходиться к теоретической плотности распределения. Реализованный код позволяет наглядно наблюдать эту сходимость: для $n = 10$ гистограмма имеет случайные отклонения, для $n = 100$ приближение становится лучше, а для $n = 1000$ практически совпадает с теоретической кривой. Для распределения Коши, обладающего «тяжёлыми хвостами», гистограмма даже при $n = 1000$ может демонстрировать заметные выбросы, что соответствует теоретическим свойствам. Для дискретного распределения Пуассона гистограмма и теоретические вероятности также сближаются при росте n.

4 Результаты

На рис. 1–5 представлены гистограммы выборок и теоретические кривые плотностей (или функции вероятности для распределения Пуассона) для каждого из пяти распределений при объёмах выборки $n = 10, 100, 1000$. Каждый рисунок состоит из трёх подграфиков, позволяющих наглядно проследить сходимость эмпирической оценки к теоретическому распределению при увеличении объёма выборки.

Figure 1: Нормальное распределение $N(0, 1)$. При $n = 10$ гистограмма имеет заметные случайные отклонения от гладкой колоколообразной кривой. При $n = 100$ форма приближается к теоретической, а при $n = 1000$ гистограмма практически сливается с плотностью.

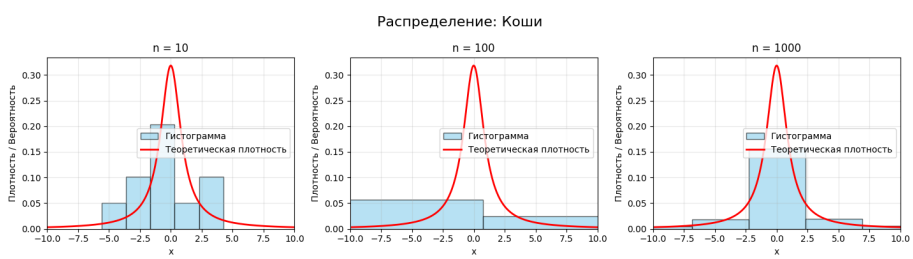

Figure 2: Распределение Коши $C(0, 1)$. Из-за тяжёлых хвостов даже при $n = 1000$ на гистограмме могут наблюдаться выбросы далеко за пределами $[-10, 10]$. Теоретическая плотность имеет более пологие спады по сравнению с нормальным распределением.

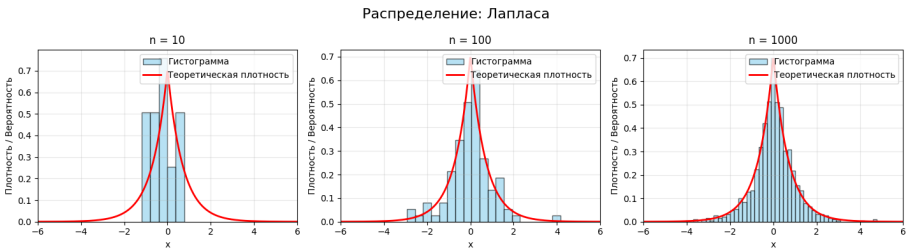

Figure 3: Распределение Лапласа $L(0, 1/\sqrt{2})$. Характерная «острая» вершина в нуле и экспоненциальные спады. Гистограмма уже при $n = 100$ хорошо воспроизводит форму плотности.

Figure 4: Распределение Пуассона $P(10)$. Дискретное распределение: гистограмма нормирована на сумму, равную 1, а теоретические вероятности отмечены красными точками. При $n = 10$ гистограмма далека от истинных вероятностей, при $n = 100$ становится похожей, а при $n = 1000$ практически точно повторяет функцию вероятности.

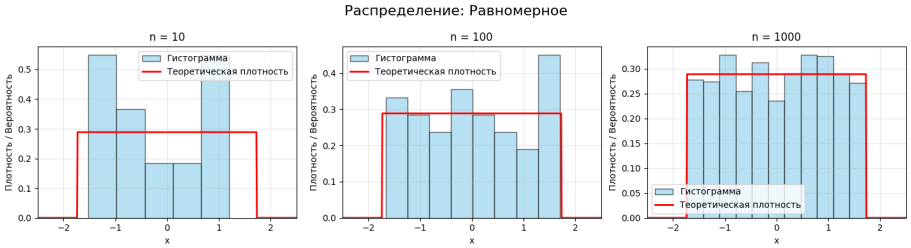

Figure 5: Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$. Теоретическая плотность постоянна на интервале. Уже при $n = 100$ гистограмма близка к прямоугольной форме, а при $n = 1000$ границы выборки почти точно соответствуют заданным (-1.732 и 1.732).

5 Обсуждение

Для всех распределений прослеживается чёткая тенденция: при увеличении объёма выборки гистограмма приближается к теоретической плотности. При $n = 10$ гистограмма носит ярко выраженный случайный характер — отдельные интервалы могут сильно отличаться от истинной плотности. При $n = 100$ форма гистограммы уже узнаваема, однако ещё заметны локальные флуктуации. При $n = 1000$ гистограмма практически совпадает с теоретической кривой, что подтверждает состоятельность гистограммы как оценки плотности.

Особенности отдельных распределений

- **Нормальное распределение:** сходимость происходит быстро. Уже при $n = 100$ гистограмма имеет характерную колоколообразную форму, симметричную относительно нуля.
- **Распределение Коши:** из-за тяжёлых хвостов даже при $n = 1000$ на гистограмме иногда встречаются выбросы далеко за пределами $[-10, 10]$. Это соответствует теоретическому свойству: у распределения Коши не существует математического ожидания, и выборка может содержать очень большие по модулю значения.
- **Распределение Лапласа:** хорошо аппроксимируется гистограммой уже при $n = 100$. Острая вершина в нуле и экспоненциальные спады отчётливо видны.
- **Распределение Пуассона:** для дискретного случая гистограмма с целочисленными интервалами и наложенные точки теоретических вероятностей показывают сходимость по вероятности. При $n = 1000$ эмпирические частоты почти не отличаются от теоретических $p(k)$.
- **Равномерное распределение:** гистограмма при $n = 100$ уже близка к прямоугольной форме. Границы выборки при $n = 1000$ практически точно совпадают с $-\sqrt{3}$ и $\sqrt{3}$.

6 Выводы

Размер выборки напрямую определяет качество оценки плотности распределения с помощью гистограммы. При малом объёме ($n = 10$) гистограмма имеет ярко выраженный случайный характер и не позволяет судить об истинном виде распределения. При $n = 100$ проявляются основные черты распределения (симметрия, островершинность, наличие хвостов), однако сохраняются локальные флуктуации. При $n = 1000$ гистограмма практически точно повторяет теоретическую кривую, что позволяет надёжно идентифицировать тип распределения. Таким образом, увеличение объёма выборки монотонно повышает точность и устойчивость гистограммы как эмпирической оценки плотности.

7 Список литературы

Гмурман, В. Е. Теория вероятностей и математическая статистика : учебное пособие для студентов вузов / В. Е. Гмурман. — 12-е изд., перераб. — Москва : Юрайт, 2010. — 478, [1] с. — ISBN 978-5-9916-0616-5.

8 Приложение

Ссылка - `https://github.com/fedqqq/MatStat/blob/main/Lab1/histograms.py`